Projet de Régression Linéaire

Analyse des facteurs influençant la consommation de carburant des véhicules



VEILLON Camille
KERUZORET Matthieu
PICULESCU Petru

MAM3

Introduction

Rôle de data scientist

Analyse pour une revue automobile

Objectif

Relations entre consommation et facteurs explicatifs

Méthode

Régression linéaire simple et multiple et présentation du data set et explication du choix des variables retenues



Jeu de Données











32 modèles de voitures avec 7 variables explicatives quantitatives, une variable qualitative et la consommation (variable réponse)

Régression Linéaire Simple

Principe

Minimiser l'écart entre droite et nuage de points

1

Formule

$$R(a,b) = \sum_{i=1}^{n} (y_i - ax_i - b)^2$$

On effectue ainsi une régression linéaire au sens des moindres carrés. Cette méthode consiste à trouver les paramètres (a, b) pour minimiser $R(a, b)$. Ainsi, on considère le problème suivant : $F(a, b) = \text{argmin}_{a,b} R(a, b)$

2

Estimateurs

ân et ĥn non biaisés

- $\widehat{a_n} = \frac{n\sum_{k=1}^{n} x_k y_k - \left(\sum_{i=1}^{n} y_i \sum_{k=1}^{n} x_k\right)}{n\sum_{k=1}^{n} x_k^2 - \left(\sum_{k=1}^{n} x_k\right)^2}$
- $\hat{b_n} = \overline{y_n} - a\overline{x_n}$

3

Validation

Test d'hypothèse de normalité du bruit (résidus studentisés) et intervalle de confiance pour la prédiction Y

$$\widehat{\varepsilon_{i,st}} = \frac{y_i - \widehat{y_n}}{\widehat{\sigma_{n,i}}\sqrt{1-h_i}} (\text{Résidus studentisés})$$

$$\widehat{a_n} x_{\text{new}} + \hat{b_n} \pm \widehat{\sigma_n} \sqrt{1 + \frac{1}{n} + \frac{(x_{\text{new}} - \overline{x_n})^2}{\sum_{i=1}^{n} (x_i - \overline{x_n})^2}} t_{1-\frac{\alpha}{2};n-2}$$

4

Test de validité de l'estimateur de a

Un estimateur de a est $\widehat{a_n}$, estimateur pour lequel on sait que :

$$T_a = \frac{\widehat{a_n} - a}{\widehat{a_n}\sqrt{\frac{1}{\sum_{i-1}^{n}(x_i - \overline{x_n})^2}}} \sim T(n-2)$$

où $T(n-2)$ désigne la loi de Student d'ordre n-2.

On pose $H_0 : a = 0$ et $H_1 : a \neq 0$. La région de rejet de H_0 est :

$$\left\{ \left| \frac{\widehat{a_n}}{\widehat{a_n}\sqrt{\frac{1}{\sum_{i=1}^{n}(x_i - \overline{x_n})^2}}} \right| > t_{1-\frac{\alpha}{2};n-2} \right\}$$

où $t_{1-\frac{\alpha}{2};n-2}$ est défini par $P\left(T \leq t_{1-\frac{\alpha}{2};n-2}\right) = 1 - \frac{\alpha}{2}$ avec T une variable aléatoire de loi $T(n-2)$.

En pratique, on calcule une p-valeur :

- si la p-valeur est plus petite que α, on décide H_1
- si la p-valeur est plus grande que α, on ne rejette pas H_0

Dans la région de rejet, le paramètre a n'apparaît plus car comme on travaille sous H_0, on a alors la connaissance que $a = 0$, ce qui ne serait pas vrai en toute généralité.

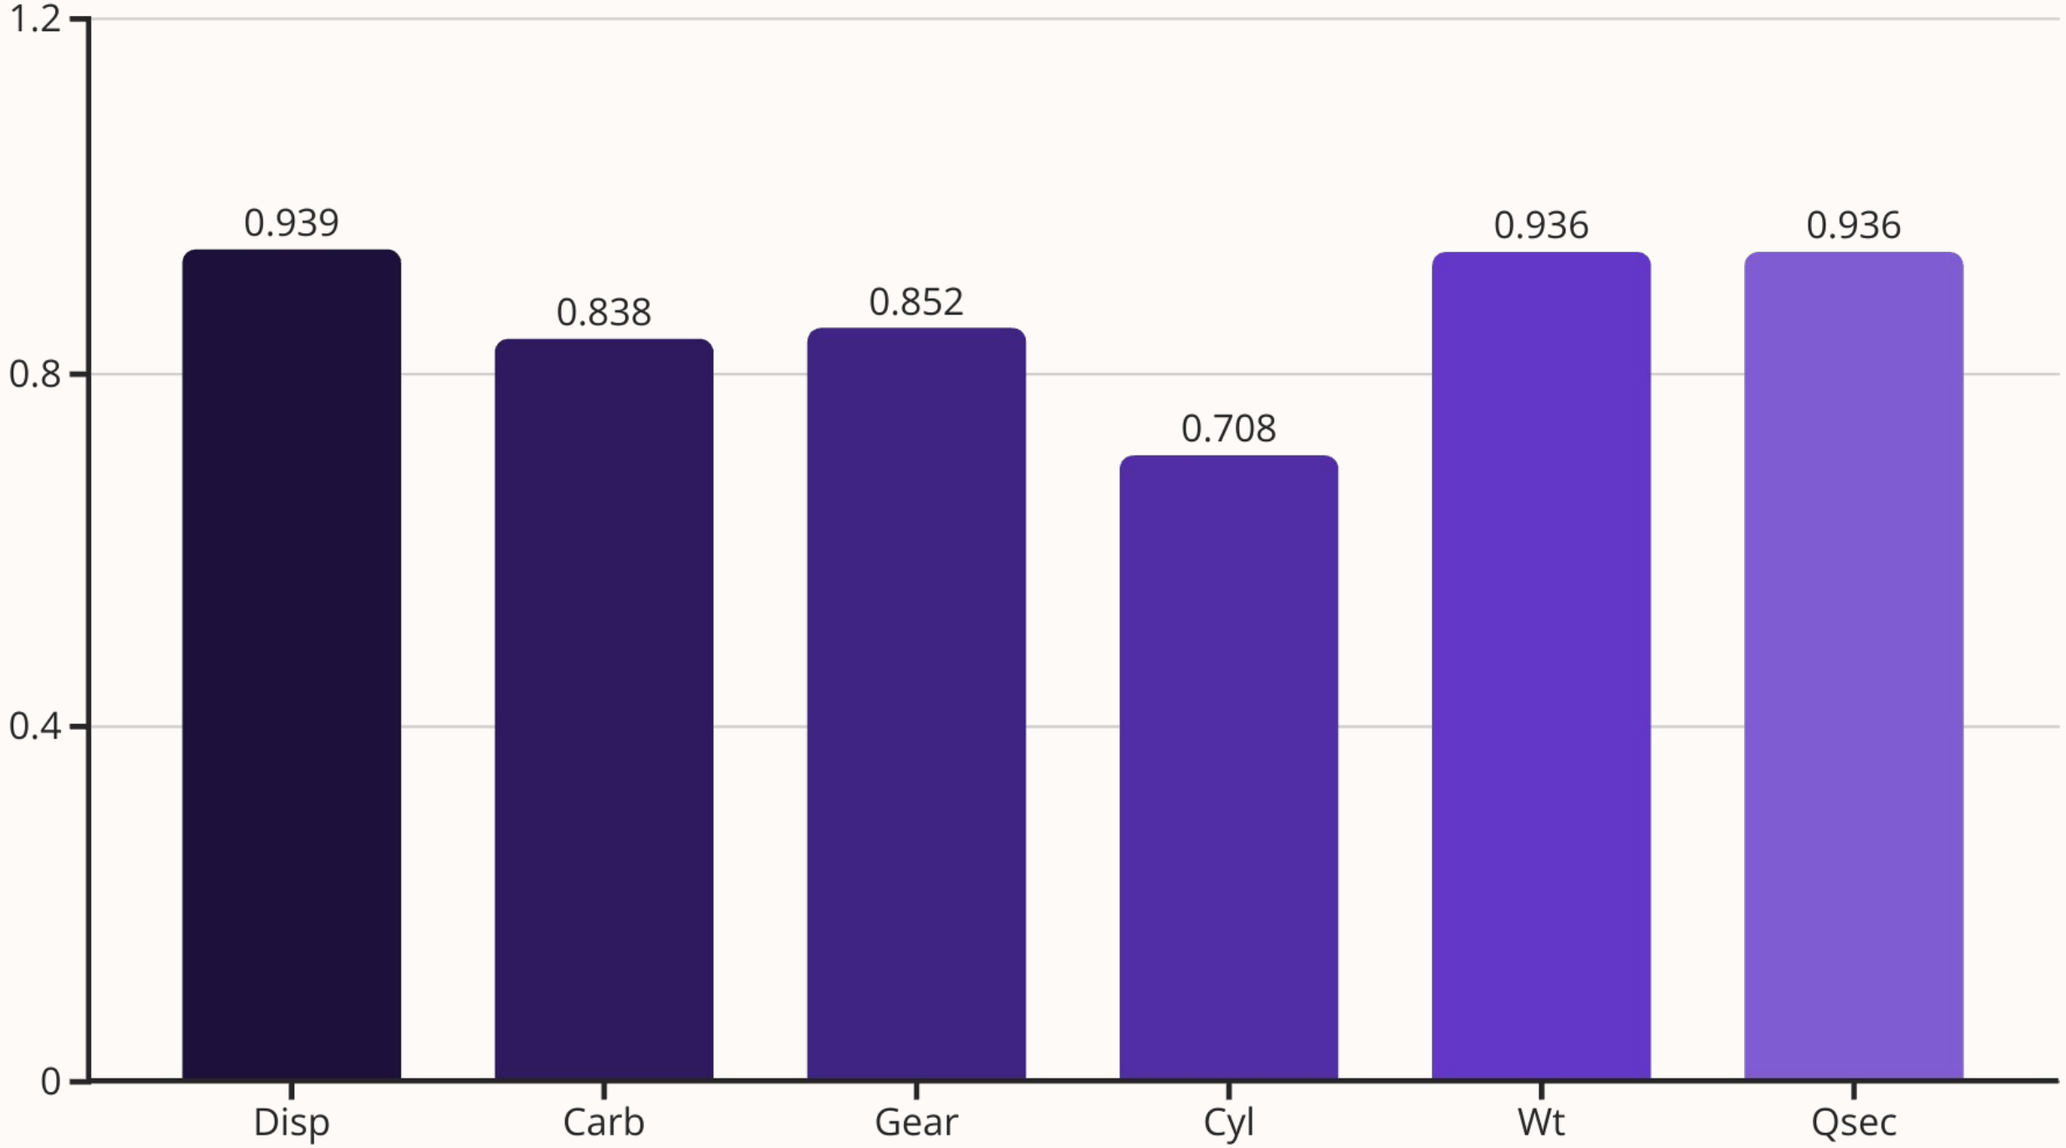
On définit la p-valeur dans le cadre du test sur le paramètre a comme étant :

$$p_{\text{valeur}} = P_{H_0}\left(|T| > |T_{a,\text{obs}}|\right)$$

où :

- $T_{a,\text{obs}}$ est la valeur calculée de T_a sur le jeu de données
- T est une variable aléatoire de loi de Student à (n-2) degré de liberté.

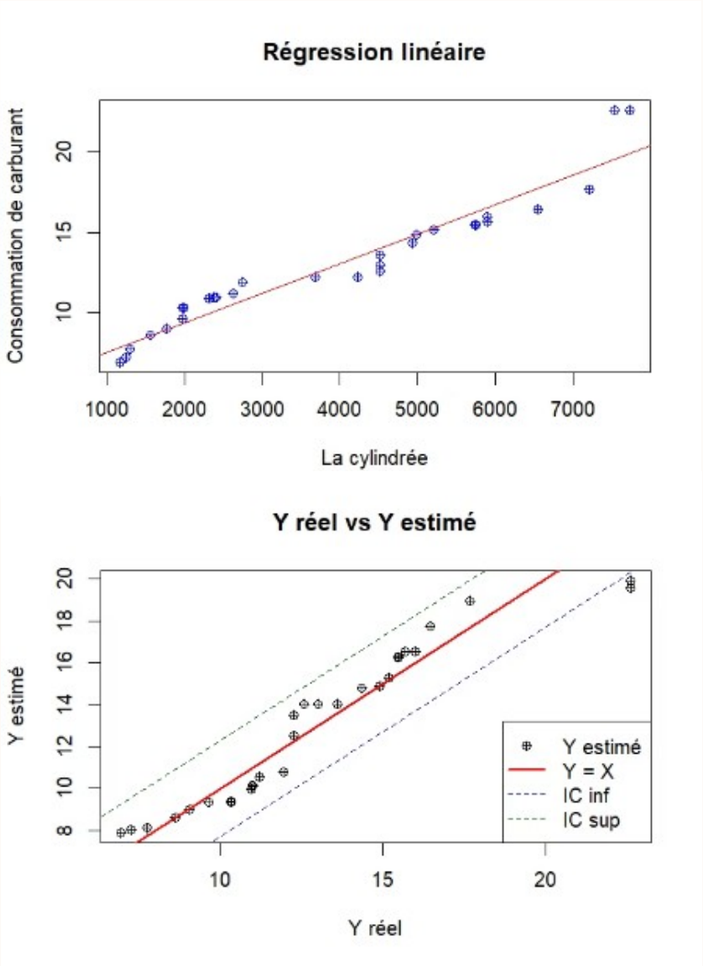
Analyse des Variables



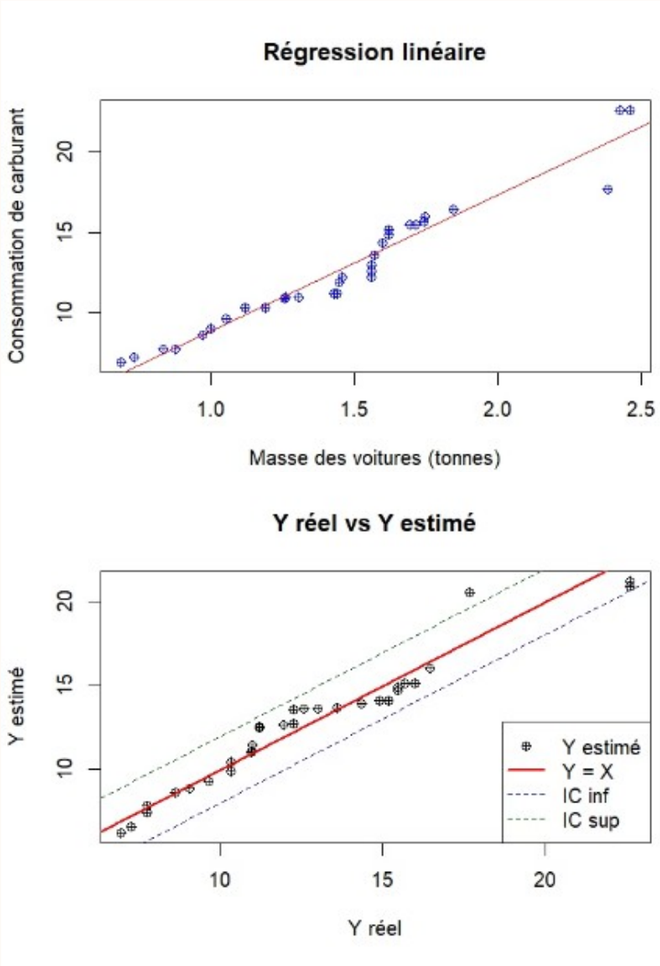
Variables avec $R^2 \geq 0,9$ retenues: cylindrée, poids, temps au 1/4 mile

Analyse des Variables

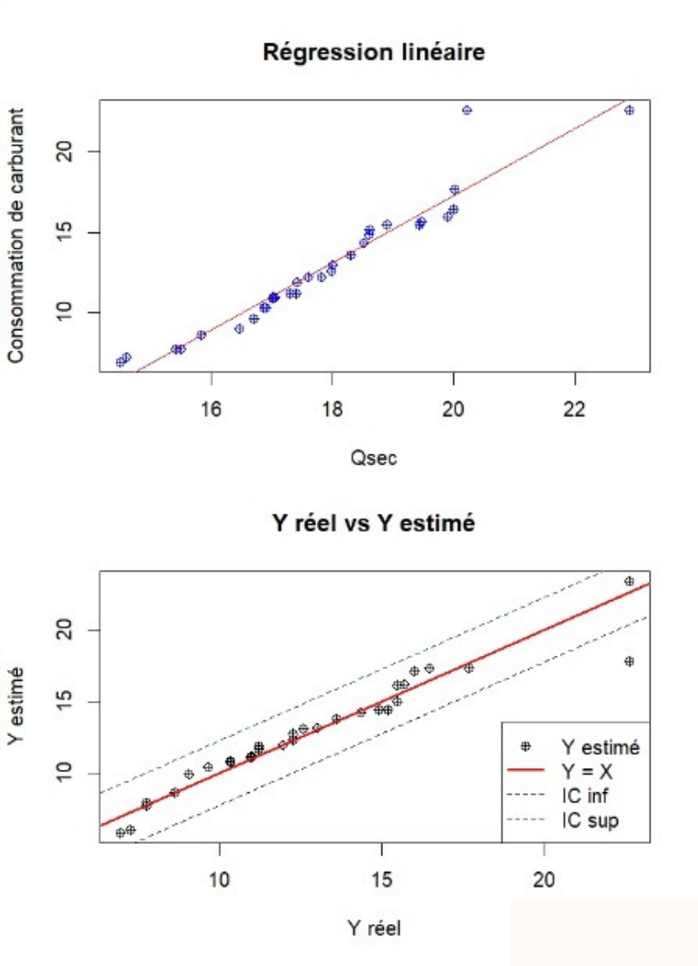
1 DISP



2 WT



3 QSEC



Régression Linéaire Multiple

Généralisation

Extension à plusieurs variables explicatives

- 1 variables réponse quantitative
- p variables explicatives quantitatives dont on dispose d'informations

Cadre Mathématique

Modèle matriciel Y = X * β + U

avec

$$\mathbb{Y} = \begin{pmatrix} Y_1 \\ \vdots \\ Y_n \end{pmatrix}, \mathbb{U} = \begin{pmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{pmatrix}, \beta = \begin{pmatrix} \beta_0 \\ \vdots \\ \beta_p \end{pmatrix}$$

$$\mathbb{X} = \begin{pmatrix} 1 & x_1^{(1)} & \dots & x_1^{(p)} \\ \vdots & \vdots & \dots & \vdots \\ 1 & x_n^{(1)} & \dots & x_n^{(p)} \end{pmatrix}$$

Moindres carrés

Estimateur de β : $(X'*X)^{-1}$ * X * Y

avec X' * X matrice inversible

Validité de la régression et qualité de la prédiction

Coefficient de détermination ajusté

Calcule du R^2 ajusté à partir du R^2 et de la formule :

$$R_a^2 = 1 - \frac{n-1}{n - rang(\mathbb{X})}(1 - R^2)$$

Test d'hypothèse

- calcul de la p-valeur
- si elle est plus petite que alpha, on décide H1
- si elle est plus grande que alpha, on ne rejette pas l'hypothèse nulle

Hypothèse de Gaussianité du bruit

Test de Kolmogorov pour vérifier que les résidus studentisés suivent bien une loi de Student à
n-rang(X) - 1 degrés de liberté

Analyse de la variance

Objectif : tester si la variable qualitative (facteur) a un effet significatif sur la variable réponse quantitative.

L'analyse de la variance (ANOVA) est une méthode statistique permettant de comparer les moyennes de plusieurs modalités.

Modèle mathématique

$$Y_i = \mu + \sum_{k=1}^{I} \mu_k \cdot \mathbb{1}_{x_i = a_k} + \varepsilon_i$$

- μ : effet global (moyenne générale)
- μ_k : effet spécifique de la modalité a_k
- ε_i : terme d'erreur avec $\mathbb{E}[\varepsilon_i] = 0$, $\mathbb{V}[\varepsilon_i] = \sigma^2$, $\text{cov}(\varepsilon_i, \varepsilon_j) = 0$

Représentation matricielle

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$$

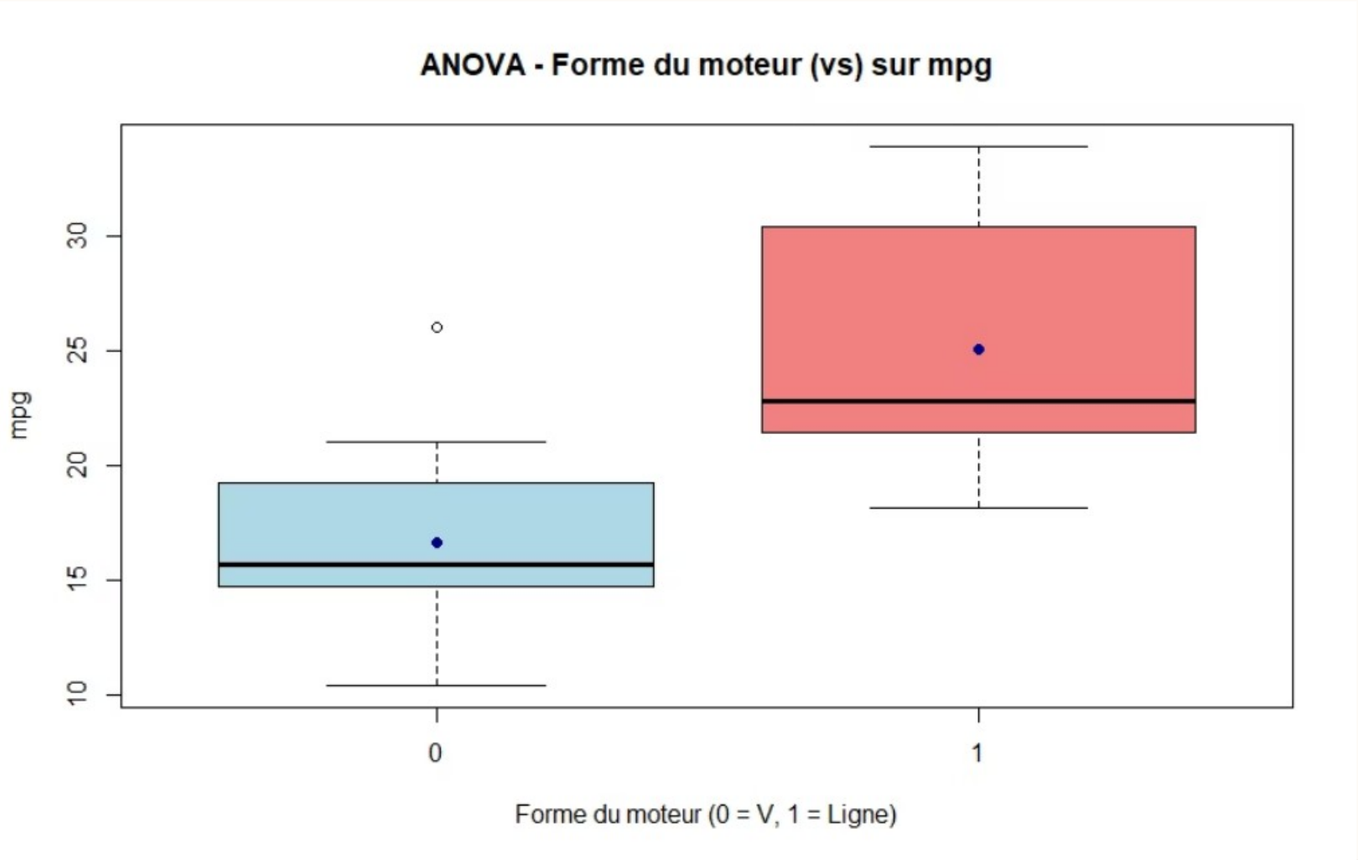
Made with GAMMA

P-value

On vérifie si la p-value est inférieure ou pas à 5% pour chaque groupe.

- Si <5%, on vérifie H1, les moyennes ne sont pas égales → influence potentielle du facteur sur la variable réponse.
- Si > 5%, on vérifie H0 → pas d'influence notable du facteur sur la variable réponse.

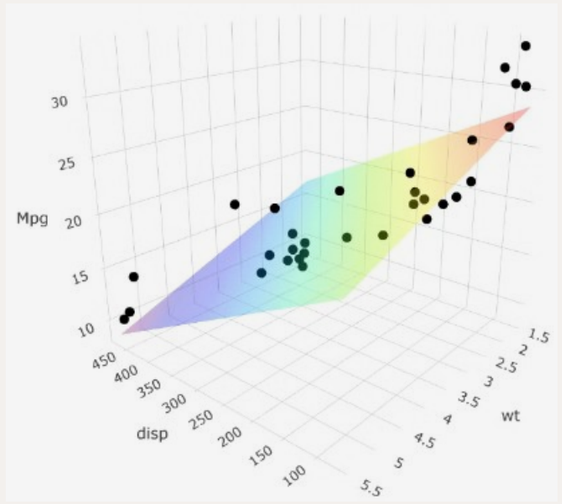
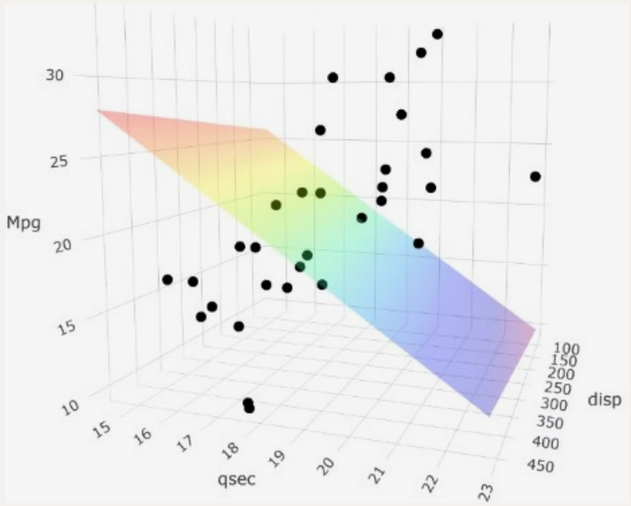
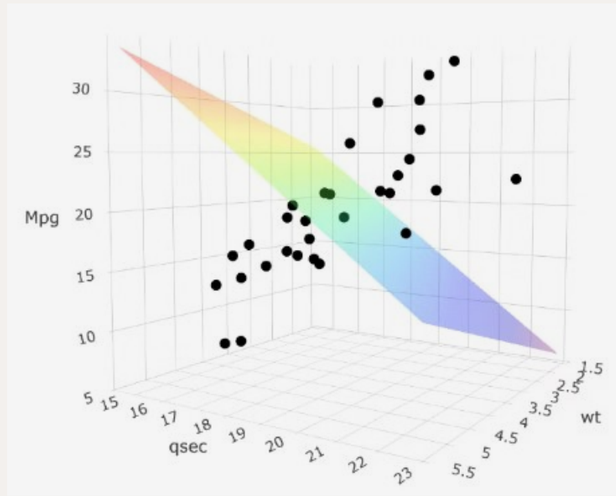
Boîtes a moustaches



Si les moyennes des boîtes à moustaches varient entre les groupes, cela signifie qu'il y a un effet potentiel du facteur sur la variable réponse.

Made with GAMMA

Comparaisons des modèles multiples

Modèle	disp ~wt	disp ~ qsec	wt ~ qsec
R^2	0,7870	0,7439	0,8288
R^2 ajusté	0,7718	0,7256	0,8177
R^2 (lm)	0,7869834	0,7438697	0,8298731
R^2 ajusté (lm)	0,7717679	0,7255746	0,8177212
p-valeur	3,96e-10	5,23e-10	1,7e-11
ks p-valeur	0,236	0,5	0,716
Représentation 3D			

Comparaisons des modèles multiples

Modèle : disp ~ wt ~ qsec

R^2	R^2 ajusté	R^2 (lm)	R^2 ajusté (lm)	p-value	ks p-value
0,8302	0,8114	0,8302464	0,8113849	1,57e-10	0,65

Modèles valides et précis

Meilleur R2

Modèle à 3 variables

Meilleur R2 ajusté

Modèle wt ~ qsec

Conclusion

Facteurs clés

Poids, cylindré et performance déterminent la consommation

Modèle efficace

93% de la variance expliquée en régression simple

Application pratique

Outil simple pour prédire et comprendre la consommation selon les caractéristiques techniques des voitures

